DETECÇÃO DE FRAUDES EM

TRANSAÇÕES FINANCEIRAS

Análise Exploratória de Dados e Modelagem Preditiva com Machine Learning

50.000	**25**	**2.423**	**4,85%**
Registros totais	Features originais	Transações fraudulentas	Taxa de fraude

Dataset: FraudShield Banking Data • Fonte: Kaggle

Autor: Ysrael de Jesus Sacramento

Algoritmo: Regressão Logística • Técnica de balanceamento: SMOTE • Otimização: Bayesian Search

1. Introdução

Este relatório documenta a análise exploratória de dados (EDA) e o desenvolvimento de um modelo preditivo de machine learning para detecção de fraudes em transações bancárias. O projeto utiliza o dataset **FraudShield Banking Data**, disponível publicamente no Kaggle, composto por **50.000 transações** com 25 atributos cada, incluindo informações sobre o cliente, a transação, o comerciante e o comportamento histórico.

Fraudes financeiras representam um dos maiores desafios para instituições bancárias globalmente. A construção de sistemas automáticos de detecção é fundamental para mitigar perdas e proteger clientes. Este projeto aborda as etapas completas de um pipeline de ciência de dados: **coleta, limpeza, análise exploratória, seleção de features, treinamento de modelo e avaliação de desempenho**.

Objetivo principal: Identificar se uma transação é fraudulenta (**Fraud_Label = 1**) ou legítima (**Fraud_Label = 0**), utilizando as características disponíveis na base de dados.

2. Entendimento e Limpeza dos Dados

2.1 Estrutura do Dataset

O dataset contém **50.000 linhas e 25 colunas**, divididas entre 13 variáveis numéricas (**float64**) e 12 variáveis categóricas (**object**). As colunas abrangem desde identificadores de transação e cliente até métricas comportamentais como contagem de falhas e histórico de fraudes anteriores.

Variável-alvo: Fraud_Label — originalmente armazenada como string (**'Fraud'** / **'Normal'**), foi convertida para inteiro binário (1 = fraude, 0 = normal), viabilizando o treinamento do modelo supervisionado.

2.2 Tratamento de Valores Ausentes

O dataset apresentava valores nulos espalhados em diversas colunas. A estratégia de imputação foi diferenciada por tipo de variável:

- **Variáveis categóricas:** preenchidas com a categoria **'missing'** via **SimpleImputer(strategy='constant')**, preservando a informação de ausência como categoria explícita.

• **Variáveis numéricas:** imputadas com a **mediana** na etapa de preparação do conjunto de features, minimizando o impacto de outliers.

• **Variável-alvo:** as 4 linhas com **Fraud_Label = NaN** foram removidas do dataset, garantindo que o modelo aprenda apenas de amostras rotuladas.

2.3 Engenharia de Features

Duas variáveis contínuas foram discretizadas com **KBinsDiscretizer** (estratégia k-means, 10 bins), gerando categorias interpretáveis:

• **Transaction_Time → Discrete_Transaction_Time + Transaction_Time_Labels:** converte o horário (HH:MM) em minutos desde meia-noite, depois agrupa em 10 faixas horárias (ex: '09:35 – 11:59').

• **Distance_From_Home → Discrete_Distance_From_Home + Distance_From_Home_Labels:** discretiza a distância entre o local da transação e o domicílio do cliente em 10 faixas (ex: '180.68 – 240.64 km').

3. Análise Exploratória de Dados (EDA)

3.1 Distribuição da Variável-Alvo

O dataset é fortemente desbalanceado: apenas **2.423 transações (4,85%)** são fraudulentas, contra **47.573 legítimas (95,15%)**. Esse desbalanço é típico de datasets de fraude reais e exige atenção especial na fase de modelagem — métricas como acurácia simples tornam-se enganosas, e técnicas como SMOTE se tornam necessárias.

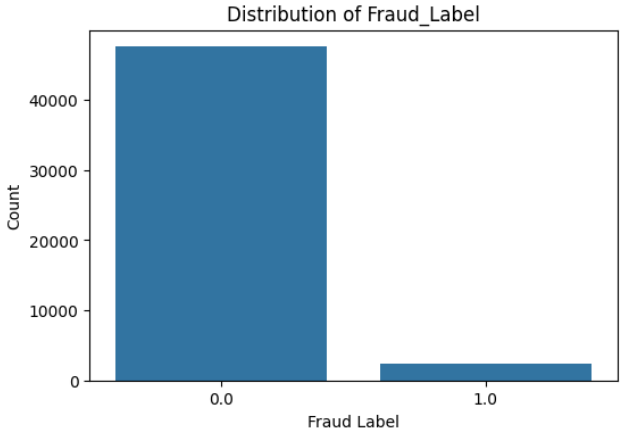

→ **Interpretação:** A grande maioria das transações é legítima. Um modelo que classificasse tudo como 'Normal' atingiria ~95% de acurácia, mas teria recall nulo para fraudes — evidenciando a necessidade de métricas como Recall, F1 e ROC-AUC.

3.2 Histórico de Fraudes por Cliente

O Gráfico de **Previous_Fraud_Count** vs. **Fraud_Label** compara a distribuição do número de fraudes prévias entre clientes fraudulentos e não-fraudulentos. A análise visa identificar se clientes com histórico de fraude têm maior probabilidade de reincidir.

3.3 Tipo de Transação e Fraude

A análise investiga se o canal de transação — **POS** (ponto de venda), **ATM** ou **Online** — está associado a uma maior incidência de fraudes. Apenas transações fraudulentas (Fraud_Label = 1) e com tipo identificado são consideradas.

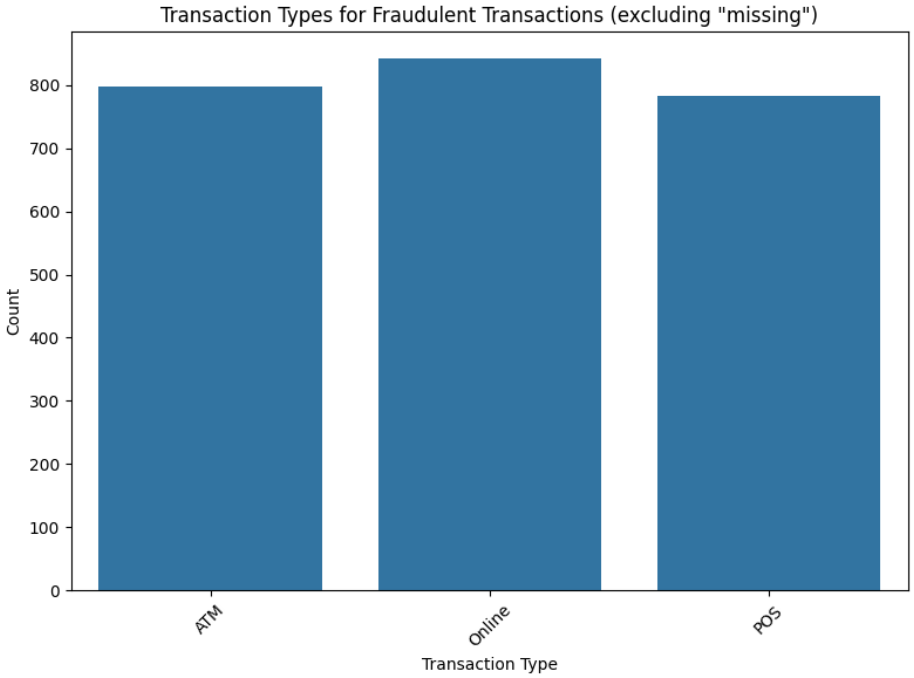

→ **Interpretação:** Uma distribuição uniforme entre os tipos sugere que o canal não é determinante para fraude. Concentração em um canal específico pode indicar vulnerabilidades naquele ponto de entrada.

3.4 Categoria do Comerciante e Fraude

O gráfico analisa quais categorias de comerciante (ex: **ATM, Electronics, Grocery, Travel**) concentram mais transações fraudulentas, revelando segmentos de alto risco.

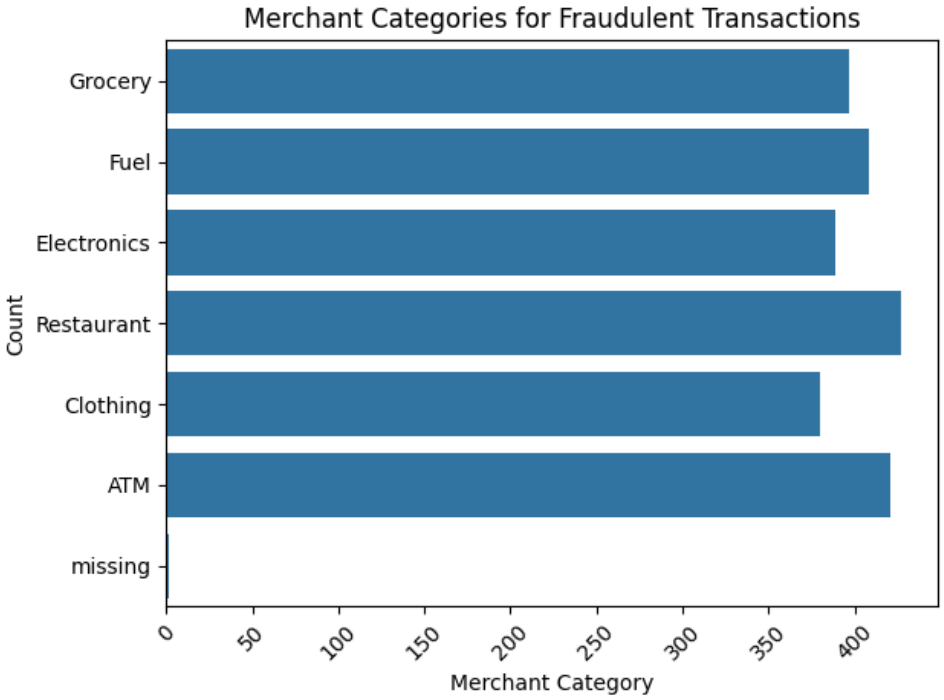

→ **Interpretação:** Categorias com maior contagem indicam setores mais visados por fraudadores. Essa informação pode guiar políticas de monitoramento mais rigoroso em segmentos específicos.

3.5 Localização da Transação e Fraude

O countplot das localizações (cidades/países) das transações fraudulentas revela regiões geográficas de maior concentração de fraudes. Como o dataset inclui transações internacionais, essa análise tem relevância para políticas de bloqueio geográfico.

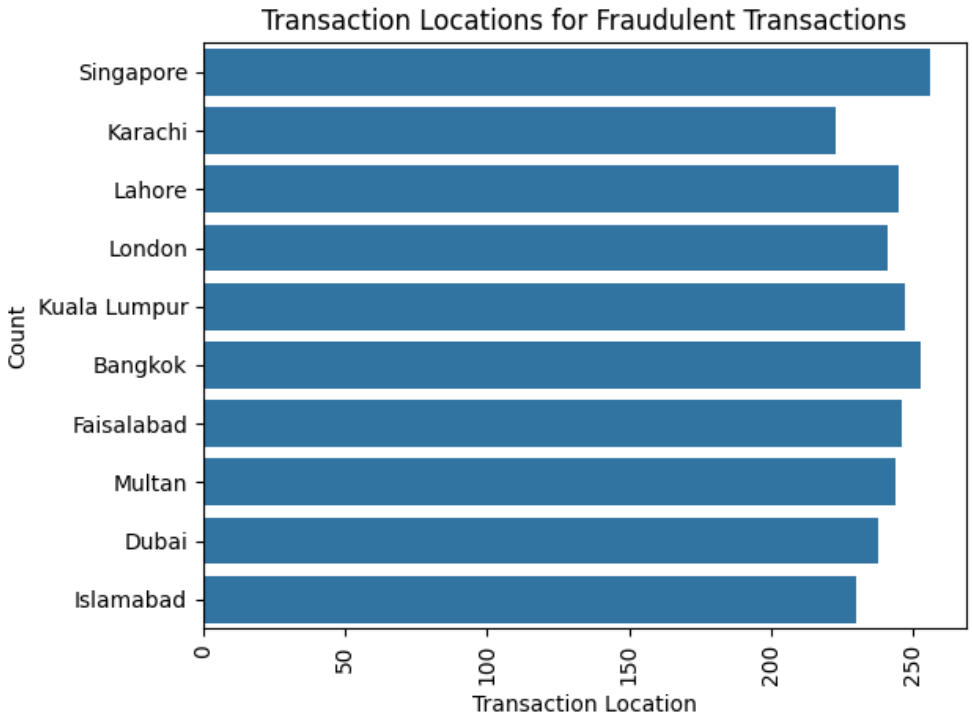

→ **Interpretação:** Localidades com alta incidência pode ser monitoradas com maior rigor. A concentração em certas regiões pode se correlacionar com a feature 'Is_International_Transaction'.

3.6 Distância do Domicílio e Fraude

A variável **Distance_From_Home** representa o quão distante da residência do cliente a transação foi realizada. Os gráficos analisam a distribuição geral das transações por faixa de distância, e depois a proporção de fraudes em cada faixa.

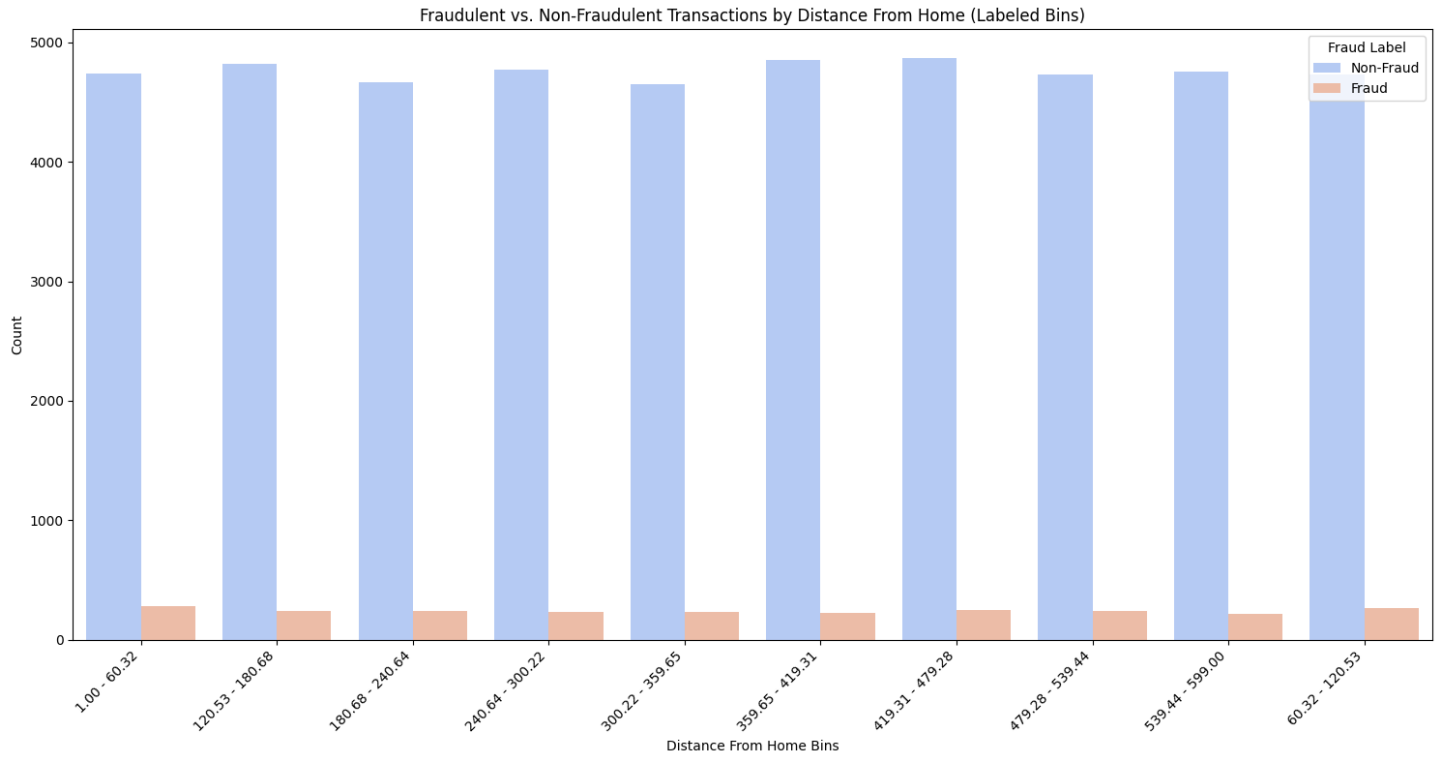

→ **Interpretação:** Espera-se que transações realizadas longe do domicílio do cliente apresentem maior incidência de fraude. Essa análise válida a relevância da feature de distância para o modelo.

3.7 Novo Comerciante, Horário Incomum e Fraude

Duas features comportamentais binárias são analisadas:

• **Is_New_Merchant:** indica se a transação foi com um comerciante nunca utilizado pelo cliente antes.

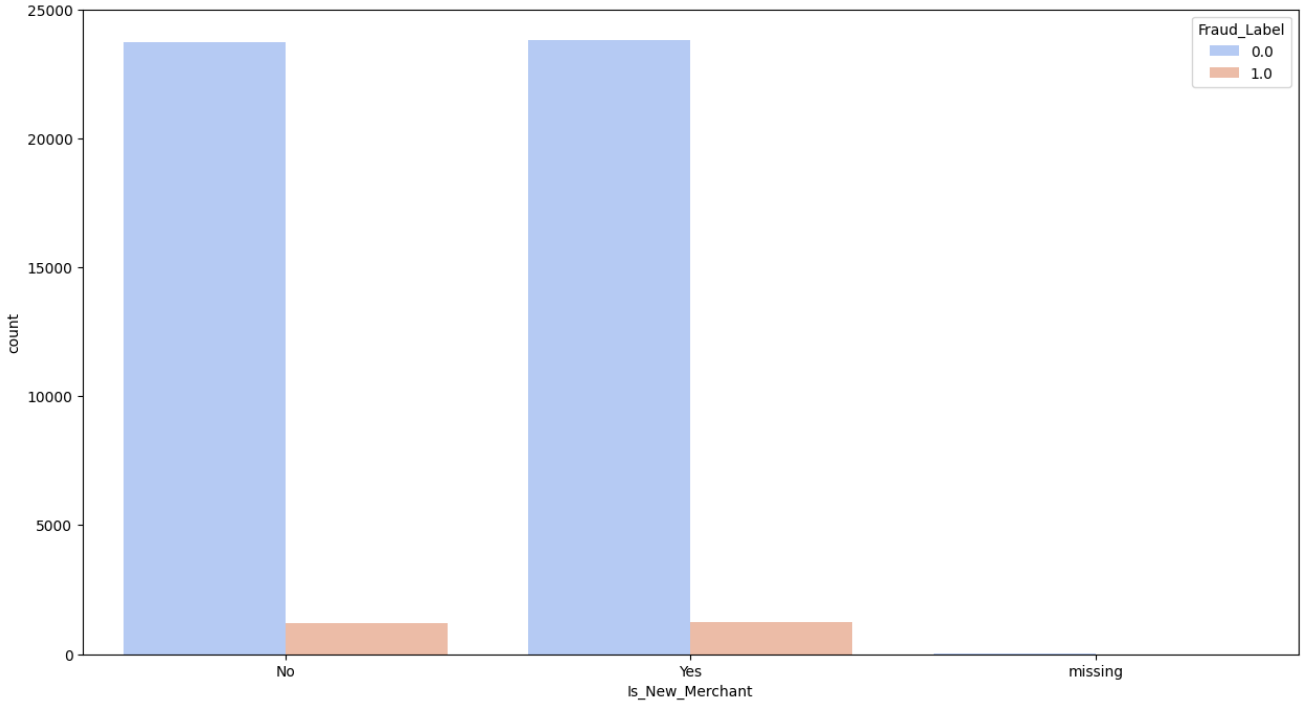

• **Unusual_Time_Transaction:** indica se a transação ocorreu em horário atípico para aquele cliente.

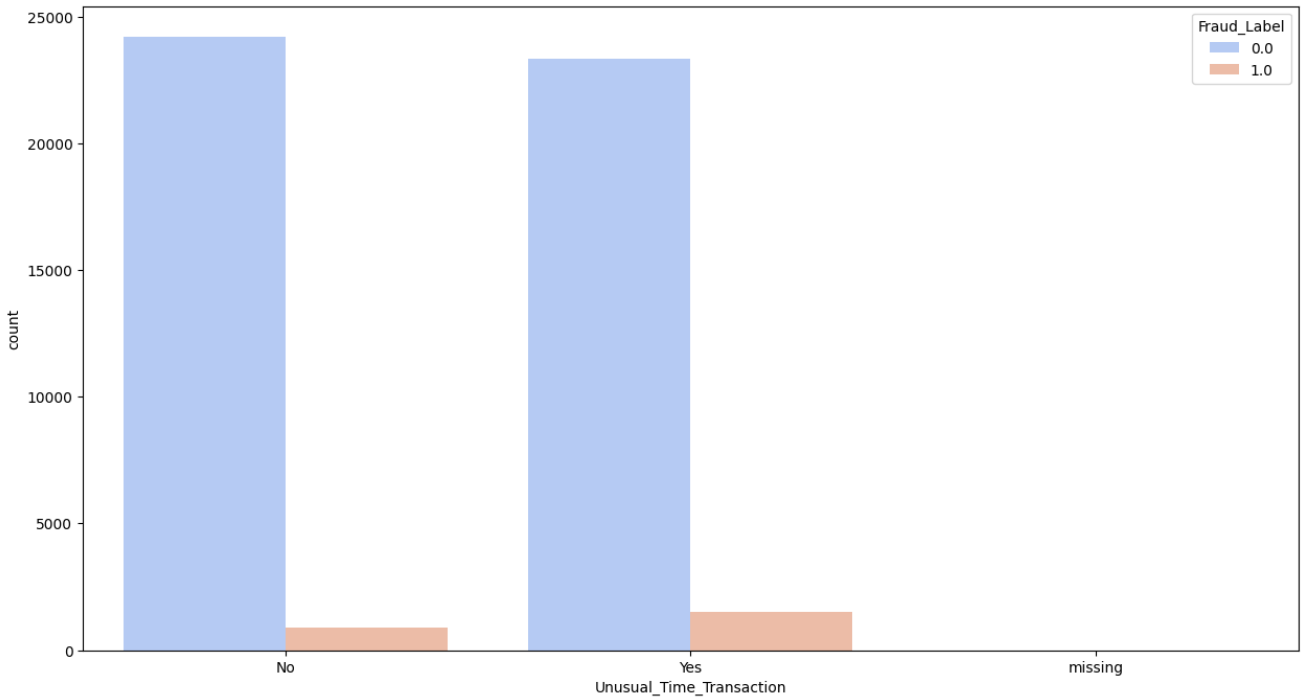

→ **Interpretação:** Transações em horários incomuns ou com comerciantes desconhecidos tendem a apresentar maior risco. O teste Chi² posterior confirmará se essa associação é estatisticamente significante.

3.8 Horário da Transação e Fraude

A variável **Transaction_Time_Labels** agrupa as transações em 10 janelas horárias ao longo do dia (ex: '02:23 – 04:47', '09:35 – 11:59'). O gráfico com hue por Fraud_Label permite identificar se certos períodos do dia concentram mais fraudes.

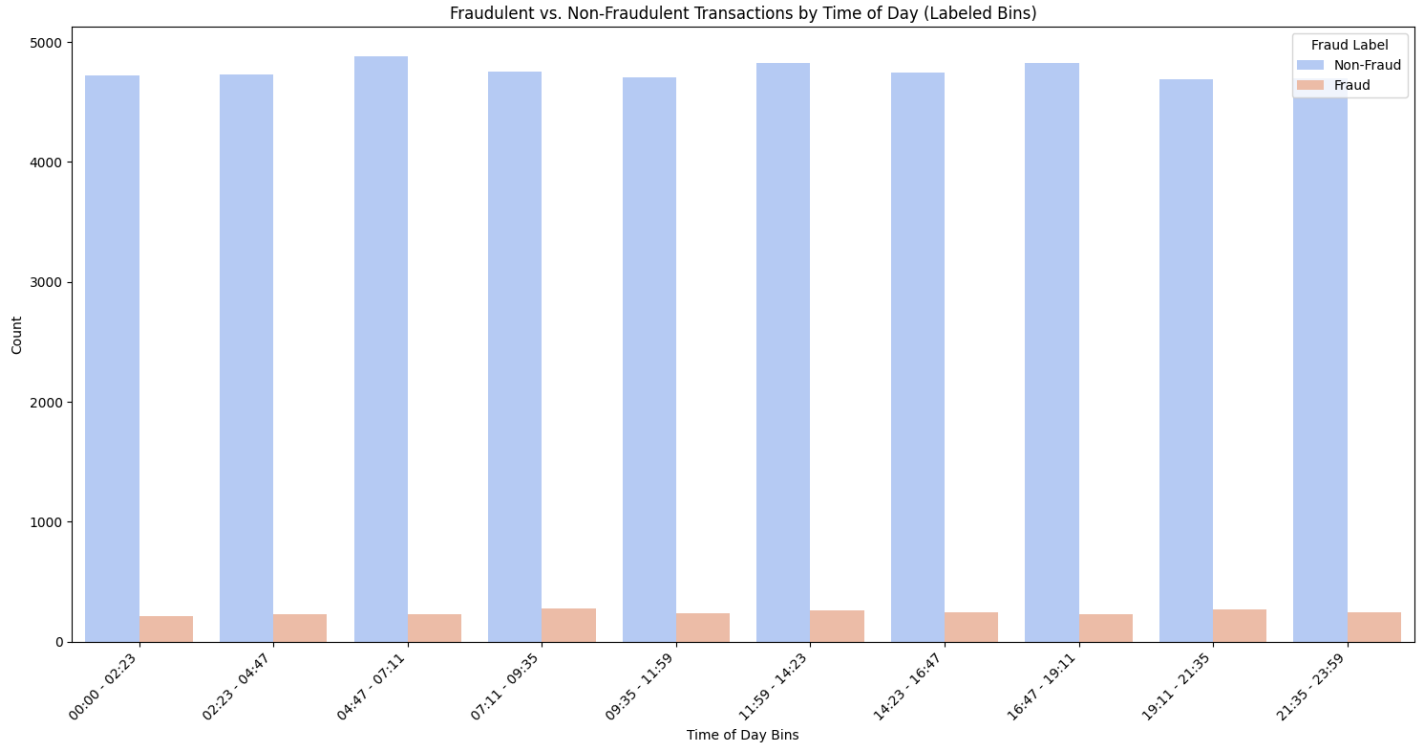

→ **Interpretação:** Horários de madrugada ou períodos de baixo volume de transações frequentemente concentram mais fraudes, pois o monitoramento em tempo real pode ser menos rigoroso nesses períodos.

3.9 Correlação com a Variável-Alvo

Um mapa de calor exibe as correlações de Pearson entre todas as features numéricas e **Fraud_Label**. Features com correlação próxima de zero foram consideradas para descarte, enquanto as com maior magnitude foram priorizadas.

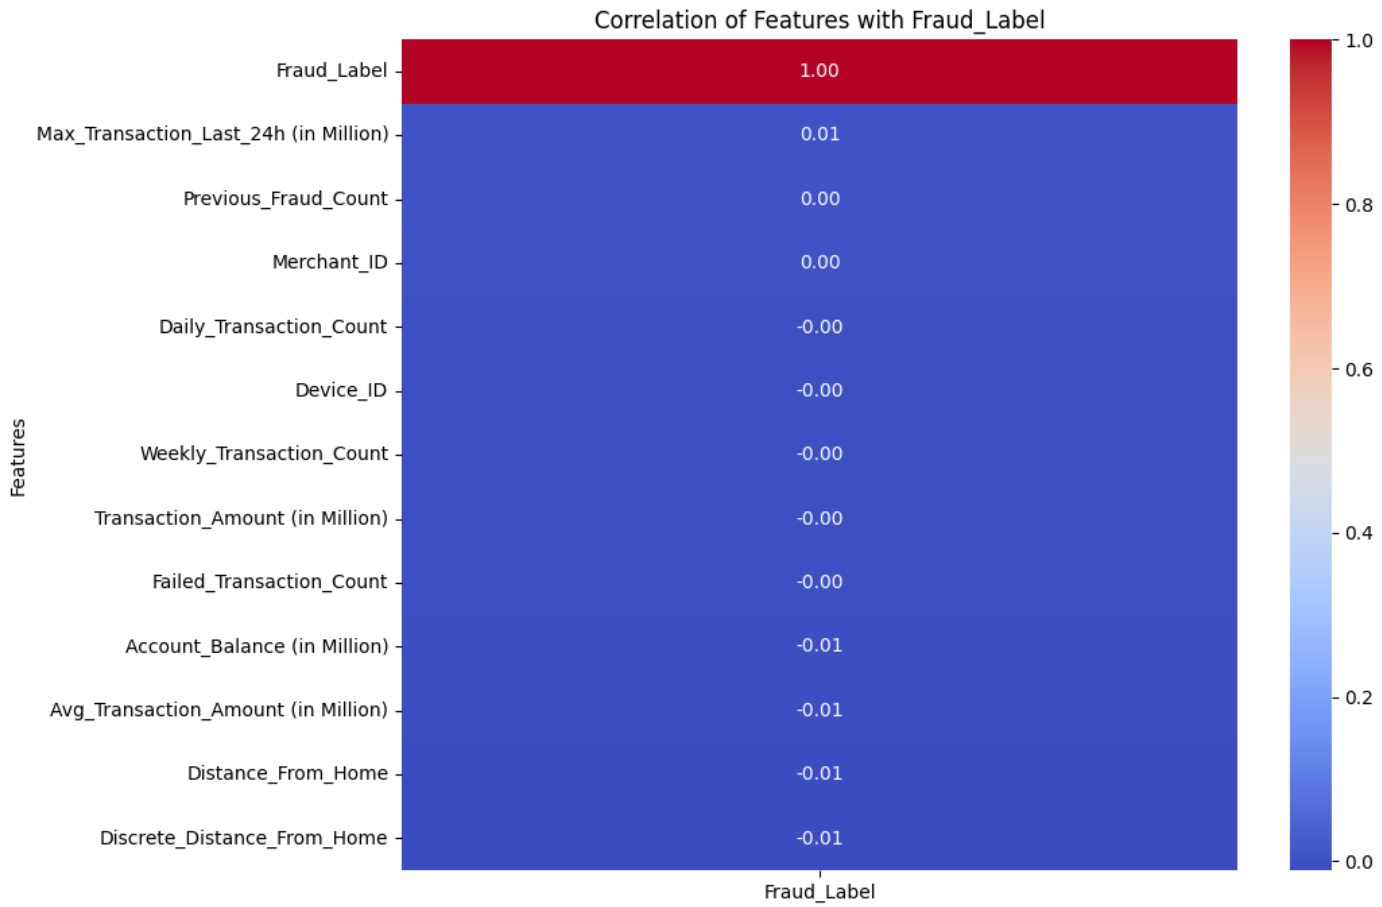

→ **Interpretação:** Features com correlação elevada (positiva ou negativa) com Fraud_Label são mais informativas para o modelo. Features com correlação ≈ 0 podem ser descartadas, reduzindo dimensionalidade e ruído.

4. Seleção de Features

4.1 Teste Chi² para Variáveis Categóricas

Para as variáveis categóricas, foi aplicado o teste **Chi-Quadrado (χ^2)** — um método estatístico que avalia a independência entre cada feature categórica e a variável-alvo. Antes do teste, as variáveis foram codificadas com **OrdinalEncoder**. Um p-value < 0,05 indica dependência estatisticamente significante com Fraud_Label.

Feature	Chi² Score	P-Value	Significância
Is_International_Transaction	90.31	2.04e-21	✓ Significante
Unusual_Time_Transaction	89.65	2.84e-21	✓ Significante
Merchant_Category	0.29	0.59	✗ Não significante
Customer_Home_Location	0.27	0.60	✗ Não significante
Is_New_Merchant	0.11	0.74	✗ Não significante
Card_Type	0.09	0.77	✗ Não significante
Transaction_Location	0.07	0.79	✗ Não significante
Transaction_Type	0.03	0.86	✗ Não significante

Os resultados revelam que apenas **Is_International_Transaction** (χ^2 = 90,31) e **Unusual_Time_Transaction** (χ^2 = 89,65) apresentam associação estatisticamente significante com a ocorrência de fraude ($p < 0,001$). As demais features categóricas não demonstraram poder discriminativo relevante e foram excluídas da modelagem.

4.2 Features Selecionadas para o Modelo

O conjunto final de features inclui:

Numéricas (13): Transaction_Amount, Merchant_ID, Distance_From_Home, Device_ID, Account_Balance, Daily_Transaction_Count, Weekly_Transaction_Count, Avg_Transaction_Amount, Max_Transaction_Last_24h, Failed_Transaction_Count, Previous_Fraud_Count, Discrete_Distance_From_Home, Discrete_Transaction_Time.

Categóricas (2, após One-Hot Encoding): Is_International_Transaction, Unusual_Time_Transaction — expandidas em colunas binárias (No / Yes / missing), totalizando 6 colunas adicionais.

Dimensão final de X: 49.996 linhas × 19 colunas.

5. Modelagem e Avaliação

5.1 Divisão Treino/Teste

O dataset foi dividido em **80% treino (39.996 amostras)** e **20% teste (10.000 amostras)** com **stratify=y**, garantindo que a proporção de fraudes (≈4,85%) seja mantida em ambos os conjuntos. Isso evita viés na avaliação causado por uma distribuição desigual da classe minoritária.

5.2 Modelo Baseline — Regressão Logística com Class Weight

O primeiro modelo treinado foi uma **Regressão Logística** com o parâmetro **class_weight='balanced'**, que ajusta automaticamente os pesos das classes inversamente proporcional à sua frequência, penalizando mais erros na classe minoritária. O solver **liblinear** foi utilizado por ser eficiente para datasets de tamanho médio.

Resultados — Modelo Baseline: Accuracy 63,39% | Precision 6,45% | Recall 48,45% | F1 11,38% | ROC-AUC 60,08%

O modelo demonstrou recall razoável (48%), mas precisão muito baixa — indicando que muitas transações normais estão sendo classificadas incorretamente como fraude (falsos positivos). Isso motivou o uso de SMOTE.

5.3 Balanceamento com SMOTE

O **SMOTE (Synthetic Minority Oversampling Technique)** foi aplicado exclusivamente ao conjunto de treino para criar amostras sintéticas da classe minoritária. O conjunto de treino passou de 39.996 amostras para **76.116 (38.058 por classe)** — perfeitamente balanceado.

Importante: o SMOTE é aplicado apenas nos dados de treino. O conjunto de teste permanece com a distribuição original, garantindo uma avaliação realista do modelo.

Resultados — Regressão Logística + SMOTE: Accuracy 62,05% | Precision 6,33% | Recall 49,48% | F1 11,23% | ROC-AUC 60,18%

5.4 Otimização Bayesiana de Hiperparâmetros

Para maximizar o ROC-AUC, foi aplicada **Otimização Bayesiana** via biblioteca **Hyperopt**, com 50 avaliações e o algoritmo **TPE (Tree-structured Parzen Estimator)**. O espaço de busca incluiu:

- **C (regularização):** amostrado em escala logarítmica no intervalo [e^{-5}, e^{0}].
- **penalty:** escolha entre L1 (Lasso) e L2 (Ridge).

Melhor configuração encontrada: C = 0.9247, penalty = L2

Resultados — Modelo Otimizado (SMOTE + Bayesian): Accuracy 60,42% | Precision 6,34% | Recall 51,96% | F1 11,30% | ROC-AUC 60,27%

5.5 Comparativo de Modelos

Modelo	Recall	ROC AUC	F1 Score
Regressão Logística (class_weight)	48,45%	60,08%	11,38%
Regressão Logística + SMOTE	49,48%	60,18%	11,23%
Reg. Logística + SMOTE + Bayesian	51,96%	60,27%	11,30%

A otimização bayesiana resultou na melhor combinação de **Recall (51,96%)** e **ROC-AUC (60,27%)**. Em detecção de fraudes, o recall é a métrica mais crítica: um falso negativo (fraude não detectada) é tipicamente mais custoso do que um falso positivo (transação legítima bloqueada).

6. Conclusões e Próximos Passos

6.1 Principais Achados

1. Desbalanceamento severo: a taxa de fraude de 4,85% exige técnicas como SMOTE e métricas além da acurácia para uma avaliação honesta do modelo.

2. Features mais relevantes: Is_International_Transaction e Unusual_Time_Transaction foram as únicas variáveis categóricas com significância estatística via teste Chi² — alinhadas ao senso comum sobre comportamentos fraudulentos.

3. Correlação numérica: o mapa de calor revelou que features como Previous_Fraud_Count, Distance_From_Home e métricas de frequência de transação têm correlação com a variável-alvo.

4. Limitações do modelo linear: a Regressão Logística, mesmo com SMOTE e otimização bayesiana, atingiu ROC-AUC de ~60%, indicando que relações não-lineares entre as features não estão sendo capturadas.

6.2 Próximos Passos Sugeridos

• **Modelos ensemble:** testar Random Forest, XGBoost ou LightGBM, que capturam relações não-lineares e tendem a performar significativamente melhor em dados tabulares.

• **Feature engineering avançado:** criar features de velocidade (transações por hora), razão valor/média histórica, e agregações por cliente.

• **Threshold tuning:** ajustar o limiar de decisão do modelo para otimizar a relação Precisão/Recall conforme o custo de negócio de cada tipo de erro.

• **Validação cruzada:** aplicar k-fold estratificado para uma estimativa mais robusta do desempenho generalizado do modelo.

• **Análise SHAP:** utilizar valores SHAP para interpretar as predições individuais do modelo e aumentar a confiança dos stakeholders na solução.